

GFCT: 面向 ICLR 2027 的研究战略*

Role C — 理论负责人

2026-08-10

摘要

本报告回答一个核心问题: 如何使 GFCT 研究线进入 ICLR 2027。结论先行: 按当前框架投稿, 几乎不可能被接收——其核心缺陷并非 FID 竞争力不足, 而在于核心理论结论与实测数据不一致。然而, 项目现有的负结果 (标量 moment-memory 预测 $h \approx 1$, 实际 $h \approx 0.837$, 且由非标量梯度残差主导) 据我们所查文献此前未被直接研究, 是唯一可发表的资产。本报告提出两项关键修订: (i) 反转论文主线, 将非标量残差作为正面贡献, 将 moment-memory 链作为被严格检验并证伪的 null model; (ii) 升级贡献类型, 从诊断升级为机制加方法——证明残差是不稳定与质量退化的原因, 并给出可修复的 residual-corrected update。报告形式化了十二个实验 (E1-E12), 按”确立现象、解析结构、确立因果、验证修复、确立普适、确立意义、确立前沿、保障稳健”的逻辑链组织, 各含可证伪假设、判定标准与风险。需强调: 本方案的核心前提——残差有害——尚未被证实, 且受到 $\text{Corr} \approx 0$ 与 $g=1.3$ 已赢 FID 数据的挑战; 任何 GPU 投入前须先判明该前提 (见正文 §3.1 与审查文档)。

目录

1	目标与约束	1
2	理论资产	1
2.1	标量等价假设	1
2.2	逐坐标 gauge	2
2.3	Moment-memory 恒等式	2
2.4	真实数据上的测量结果	2
3	现状评估: 为何按当前框架投稿会被拒	3
3.1	必须正视的前提矛盾 (对抗性审查发现)	3
4	修订方案	4
4.1	动作一: 反转论文主线	4
4.2	动作二: 升级贡献类型	4
4.3	贡献清单	4
4.4	禁止声称	4
4.5	相关工作定位	4

*团队内部科研汇报。Role C(理论负责人)。对应仓库 ‘recurrence_of_ect’。

1	目标与约束	2
5	实验计划	5
5.1	硬性门控: 残差是否有害——现已实测判定	5
5.2	实测诊断证据 (2026-08-10, 已执行)	6
5.3	E1 — 跨状态残差轨迹	6
5.4	E2 — 因果干预 (residual-corrected update)	7
5.5	E3 — 普适性	7
5.6	E4 — MeanFlow / flow-map 泛化	7
5.7	E5 — 残差结构分解	8
5.8	E6 — 剂量响应 (残差对 gap 的响应)	8
5.9	E7 — 优化器状态依赖	8
5.10	E8 — 坐标级诊断的有效性	8
5.11	E9 — 修正的权衡	9
5.12	E10 — 修复的基线对照	9
5.13	E11 — 稳健性: 多 seed 与支撑阈值敏感性	9
5.14	E12 — 残差中介 gap 到 FID	9
6	执行顺序与约束	10
6.1	执行顺序	10
6.2	各实验不得声称什么	10
7	结论	11

1 目标与约束

本工作唯一目标是使论文被 ICLR 2027 接收。该目标受两条硬性约束:

- ICLR 2026 录用率约 27.4%。即便论文撰写成熟, 被拒概率仍接近四分之三, 且审稿过程存在噪声, 任何表述歧义之处均可能被拒。
- ICLR 审稿指南明确: 缺乏 SOTA 结果本身不构成拒稿理由。因此 CIFAR-10 基准与 FID 不拔尖并非致命因素。真正的高风险在于 *soundness*——即理论与自身实测不一致。

后续所有决策均以上述两条为基准。

2 理论资产

2.1 标量等价假设

少步生成式训练普遍默认一个假设: 训练中的干预——如 schedule 或离散化 gap 的改变——标量等价于学习率改变, 即能被参数更新上的单个标量乘子吸收。形式化地, 设 $U_1(z, \xi)$ 为参考 gap $g = 1$ 下 RAdam 的单步更新, $U_g(z, \xi)$ 为候选 gap 下的更新, 两者自相同优化器状态 $z = (\theta, m, v, n)$ 与相同随机性 ξ 出发。该假设表述为

$$U_g \approx s U_1, \quad (1)$$

其中 s 为标量; 若成立, 则 gap 等价于学习率乘以 $c = 1/s$ 。

2.2 逐坐标 gauge

在参考更新的有效支撑上, 定义逐坐标更新比 *gauge*

$$h_{k,i} = \frac{U_{g,k,i}}{U_{1,k,i}}, \quad i \in \mathcal{S}_k := \{i : U_{1,k,i} \neq 0\}. \quad (2)$$

标量等价 (1) 成立当且仅当 $h_{k,i}$ 在 $\mathcal{S}_k$ 上恒为常数、且候选更新在支撑外消失 (命题 2.1)。该 *gauge* 提供对干预是否保持标量等价的逐坐标诊断。

2.3 Moment-memory 恒等式

对两臂步序号一致的 rectified RAdam,gauge 满足精确恒等式

$$h_{k,i} = \frac{(1 + A_{k,i}^{(1)})}{\sqrt{1 + 2A_{k,i}^{(2)} + B_{k,i}^{(2)}}}, \quad (3)$$

其中 $p_{tj} \propto \beta_1^{t-j}$ 、 $q_{tj} \propto \beta_2^{t-j}$, 且

$$A_{k,i}^{(1)} = \frac{\sum_j p_{kj} \delta_j G_{j,i}}{\sum_j p_{kj} G_{j,i}}, \quad A_{k,i}^{(2)} = \frac{\sum_j q_{kj} \delta_j G_{j,i}^2}{\sum_j q_{kj} G_{j,i}^2}, \quad (4)$$

$$B_{k,i}^{(2)} = \frac{\sum_j q_{kj} \delta_j^2 G_{j,i}^2}{\sum_j q_{kj} G_{j,i}^2}, \quad \delta_j = \frac{\langle G_j^g, G_j \rangle}{\|G_j\|^2} - 1. \quad (5)$$

其中 G_j 为参考梯度, G_j^g 为候选梯度, δ_j 为每步最优拟合的标量尺度。(3) 为精确恒等式而非 Taylor 近似; 其一阶推论为 $h - 1 = A^{(1)} - A^{(2)} + O(\|\delta\|^2)$ 。

命题 2.1 (标量等价当且仅当 *gauge* 恒定). 对步序号一致、*eps* 为零、无 *weight decay* 的 rectified RAdam, $U_g = s U_1$ 当且仅当对一切 $i \in \mathcal{S}_k$ 有 $h_{k,i} = s$ 、对一切 $i \notin \mathcal{S}_k$ 有 $U_{g,k,i} = 0$ 。精确投影残差的平方满足

$$\|U_g - s_k^* U_1\|^2 = \sum_{i \in \mathcal{S}_k} w_i (h_{k,i} - s_k^*)^2 + \sum_{i \notin \mathcal{S}_k} U_{g,k,i}^2, \quad (6)$$

其中 $w_i = U_{1,k,i}^2$ 、 $s_k^* = \langle U_g, U_1 \rangle / \|U_1\|^2$ 。

2.4 真实数据上的测量结果

在真实 256 king ECT 状态上进行的 paired counterfactual 审计 (gap 1.0 vs. 1.3, 随机性逐位一致) 得到如下结果:

- **标量 null 在有效支撑上成立。**由 (3) 预测的 *gauge* 为 $h \approx 1.001$, 其中 $A^{(1)} \approx A^{(2)} \approx -0.23$, 相互抵消。
- **实际更新比系统性偏移。** $h_{\text{actual}} \approx 0.837$, 分布高度集中, $\text{Corr} \approx 0$ ——预测与实际稳定地不同。

- 主导因素为非标量梯度残差。每步存在量级约 3.2% 的非标量残差 E_j , 主导更新失真; 标量链 (3) 无法捕捉该偏移。

需要说明的是, 这是一个真实且有价值的发现。领域的 scale-invariance 文献 ($\beta_1=\beta_2$ 、Adam-atan2、DeVA) 均分析标量/全局缩放, 未涉及非标量残差内容。问题不在于该发现本身, 而在于其当前被置于论文末尾作为结论性说明, 而非作为核心论点。

3 现状评估: 为何按当前框架投稿会被拒

核心理论 moment-memory 预测 $h \approx 1$, 而实测 $h \approx 0.837$, 且如我们自身所承认, 驱动因素为理论未建模的非标量残差。置于 ICLR 最看重的 soundness 标准下, 审稿人面对”理论预测 1, 实测 0.84, 原因未被理论覆盖”时, 通常判定为理论有误或论文前后不一致——审稿人不会代为重构叙事。

此外, 研究对象为 CIFAR-10 上的普通 ECM/DDPM++ 一致性模型, 而领域已整体转向 MeanFlow / flow map、RL 后训练与蒸馏, 一致性模型亦逐步走向连续时间、取消离散化。FID 亦不具竞争力。上述因素单独均非致命, 叠加后进一步削弱竞争力。

本质上, 当前框架属于诊断性质, 而诊断天然狭窄、且具有负结果属性。ICLR 主会不倾向接收负结果, 狭窄的新颖性在 27.4% 录用率下空间有限。仅对现有内容做进一步打磨, 无法突破这一限制。

3.1 必须正视的前提矛盾 (对抗性审查发现)

将贡献升级为”机制 + 方法”的前提是: 残差是质量退化的原因, 故修正它能改善质量。然而该前提被我们自己的数据直接反驳:

- 头号相关为约零。现有 paired 审计测得 $\text{Corr} \approx 0$ ——残差与结果几乎没有相关。
- 带残差的 $g=1.3$ 臂大幅胜出 (已实测)。在被测残差的同一批状态上 (gap_lr_matched_q128_s3_v1 的 arm_a $g = 1.0$ vs. arm_b $g = 1.3$, 两者 global_sigmoid、lr 固定), $g = 1.3$ 的 FID-5k 相对 $g = 1.0$ 改善约 34-36%(NFE1: 208.1 vs. 315.8; NFE2: 56.6 vs. 87.7), KID 改善约 37-45%。带非标量残差的臂质量明显更好。因此 Arm C 的”修复”不仅修一个没坏的东西, 还会向 $g = 1.0$ 更差的 FID 移动——E2 因果干预被该数据反指 (详见 analysis/g13_vs_g10_fid_result.md)。
- 各向异性是自适应优化器的设计功能。AdaGrad/Adam/Muon 存在的全部理由就是梯度各向异性。把候选梯度投影到标量参考方向等于标量化优化器, 可能丢掉真实信号——Arm C 的改善与”换了个优化器”难以区分。

因此, “机制 + 方法 40-50%” 的估计过度乐观。现实区间 (见审查 ‘docs/ICLR2027_PLAN_REVIEW.md’): 坚持机制 + 方法约为 10-15%; 收缩为诚实的诊断 (非标量梯度内容的结构刻画, 此点在 2025-26 文献中确实未被占据) 约为 20-30%。* 在任何 GPU 投入之前, 必须先判明残差是否真的有害。

**

4 修订方案

需进行两项修订,二者均不可偏废。

4.1 动作一: 反转论文主线

将非标量梯度残差作为正面贡献, moment-memory 链降级为被严格检验并证伪的 *null model*。后者并非失败, 而是用于度量“标量等价在何处失效”的基准工具。

4.2 动作二: 升级贡献类型

将贡献从诊断 (一项测量加一项警示) 升级为机制加方法。论文应呈现为:

在少步训练中识别出一个失败模式 (非标量梯度残差), 证明其是不稳定与质量退化的原因, 并给出能将其修复的 residual-corrected update。

诊断型论文的录用概率约 20–30%; 机制加方法型约 40–50%。

4.3 贡献清单

1. 标量等价性的 state-conditioned 形式化——首个严格的、逐坐标的、状态条件的处理: 训练干预是否等价于学习率变化。
2. 一项新的测量手段: 支撑感知的 gauge 离散度 (support-aware gauge dispersion)。
3. 一项可证伪的警示性结论: 主导更新失真是非标量梯度内容, 而非标量 moment-memory。
4. 一个机制 (E1): 残差预测不稳定与质量退化。
5. 一个方法 (E2): 将 h 恢复至 1 的 residual-corrected update, 可改善稳定性与 FID。

4.4 禁止声称

下列声称已被既有文献占据, 写入将直接削弱新颖性声明, 应明确禁止: “首次自适应离散化”(ADCM)、“首次 optimizer-aware update matching”(Filter-then-Weight)、“首次优化器不变性分析”($\beta_1=\beta_2$ 、Adam-atan2、DeVA)、“首次 history-gauge 定理”($H_k = R_{\text{opt}}(k)$ 为本项目内部恒等式)、“gap 等价于改变学习率”(已被 $h = 0.837$ 推翻)。

4.5 相关工作定位

相关工作部分须逐条说明差别: $\beta_1=\beta_2$ 为全局标量结果; Adam-atan2 与 DeVA 处理标量缩放分解; ADCM 为质量优化 schedule, 不涉及 optimizer-state 等价; SCT 讨论目标/方差理论, 不讨论更新几何; Dead-Direction Conditioners 的 “gauge” 指对称轨道——本项目的 gauge 改称为 “逐坐标更新比 gauge”, 以避免术语撞车。

5 实验计划

E1 与 E2 为门控实验, 决定论文属于机制加方法还是诊断。为使” 机制 + 方法” 论证在审稿面前严密, 本计划将实验扩展为一个完整程序, 按逻辑链组织:

1. 确立现象 — E1(残差跨状态预测失败)
2. 解析结构 — E5(残差分解)、E6(剂量响应)、E7(优化器状态依赖)
3. 确立因果 — E2(残差修正干预)
4. 验证修复 — E8(诊断有效性)、E9(修正权衡)、E10(修复基线)
5. 确立普适 — E3(普适性)
6. 确立意义 — E12(残差中介 gap 到 FID)
7. 确立前沿 — E4(MeanFlow 泛化)
8. 保障稳健 — E11(多 seed 与支撑阈值敏感性)

其中 E1、E5、E6、E7、E2 共同构成” 机制” 论证:E1 证明残差预测失败,E5 解析其结构、E6 证明其为干预的系统函数、E7 证明其效应依赖优化器状态,E2 用受控干预确立因果。E8、E9、E10、E12 共同构成” 方法” 论证:E8 证明残差可预测、E9 给出可调的修正、E10 证明修正的针对性、E12 将整个优化器分析连接到生成质量。E3 与 E4 建立普适性与前沿相关性;E11 保障全部结论的稳健性。

5.1 硬性门控: 残差是否有害——现已实测判定

对抗性审查 (见 ‘docs/ICLR2027_PLAN_REVIEW.md’) 确认, 本方案最薄弱的环节是 E2 的前提——残差有害。原计划要求先完成两项零成本判定。该判定现已执行并得到决定性结论 (见 ‘analysis/g13_vs_g10_fid_result.md’):

1. 严格推导 3.2% 幅值到 16% h 偏移的归因 (即 $1.001 \rightarrow 0.837$)。尚未完成; 该数字仍无推导。若无法推出, 反转主线不依赖此数字。
2. 预注册一个带残差那臂真正退化的指标, 并调和它与 $g=1.3$ 已赢 FID 的矛盾。已完成 (实测): 干净对比 $g=1.3$ vs. $g=1.0$ 的 FID-5k/KID-5k 显示 $g=1.3$ (带残差的臂) 在 NFE1/NFE2 全面大幅胜出 (FID $-34/-36\%$, KID $-37/-45\%$)。** 未找到任何残差导致退化的指标。**

结论: 机制 + 方法前提被实测数据证伪。带非标量残差的臂质量明显更好, 残差 无害。E2 因果干预不仅无支撑, 而且被反指——Arm C(投影回 $g=1.0$ 方向) 会向更差的 FID 移动。

因此,E2 从” 门控因果实验” 降级为” 探索性消融”。不将其作为论文主结果, 不作为机制 + 方法的支撑; 仅作为验证” 残差修正方向与质量方向相反” 的一次消融, 并作为” 设计启示”(gap 的非标量部分对应更优质量) 报告。

论文定位: 收缩为诚实诊断。可辩护的贡献: 非标量梯度残差存在且有结构 ($a_K^*=0.761$ 、 $R_{\text{grad}}=5.85\%$ 、 $R_{\text{opt}}=8.57\%$ 、 $H_K=R_{\text{opt}}$ 精确成立、标量 null 被证伪: 预测 1.001 vs. 实测 0.837), 但它无害——带它的臂质量更好。此点此前未被 2025–26 标量 scale-invariance 文献覆盖。

剩余可选诊断实验 (不依赖”残差有害”): E5 结构分解、E6 剂量响应、E7 优化器状态依赖、E11 稳健性——这些描述残差的结构与规律, 不声称其有害, 仍然可做且增强诊断论文。

5.2 实测诊断证据 (2026-08-10, 已执行)

诊断定位已由实测数据支撑 (详见 ‘analysis/e5_residual_structure_result.md’、‘analysis/e6_dose_respon

- **E5 残差有结构 (非噪声)**。坐标 gauge 偏离 1 的程度随层深增大 (pearson +0.46); 残差与更新幅值无关; 梯度方向残差随 $|g-1|$ 单调增长。层级 gauge 偏离小 ($\sim 3-5\%$) 且集中, 无单一”坏层”。
- **E6 剂量响应: 残差与 FID 强反相关**。残差单调于 $|g-1|$; 而 FID 在 $g=1.0$ (零残差) 最差、 $g=1.3$ (最大残差) 最佳 ($\text{corr}(\text{残差}, \text{FID}) \approx -0.99$)。零残差臂最差, 残差无害。
- **E7 优化器状态依赖 (已用直接法完成)**。绕过审计的 sigmoid 门控, 直接调用 `run_stateful_pair` 在 `arm_a` 各 tick(不同 n_K) 上测量: 梯度残差 R_{grad} 随优化器成熟度增长 ($n_K=243 \rightarrow 1991$, $R_{\text{grad}}=0.031 \rightarrow 0.091$), 残差是状态条件的。更新失真 R_{opt} 小且平坦 ($0.012-0.017$), $R_{\text{opt}} - R_{\text{grad}}$ 为负 (优化器压缩残差)。注意: 残差大小与 $R_{\text{opt}} - R_{\text{grad}}$ 符号对测量口径敏感 (此前审计 $R_{\text{opt}}=0.086$ 、 $+0.027$; 此处 0.014 、 -0.076), 需报告口径。
- **E11 稳健性 (已用现有跨 seed 数据完成)**。1024k 预算下较大 gap 臂 ($g=1.1$) 在全部 3 个 seed 上赢 FID-50k(5/6 cell);moment-memory 的 $\text{Corr} \approx 0$ 在 $\text{atol } 1e-5/1e-6$ 下稳定。
- **E3 普适性 (已用 AdamW 完成)**。梯度残差 R_{grad} 跨 optimizer 复现 (AdamW 0.095 vs. RAdam 0.091), 是非标量梯度内容为 loss/梯度属性的证据, 非 RAdam 特有; 更新失真 R_{opt} 随 optimizer 不同 (AdamW 放大 0.39,RAdam 压缩 0.014)。

六条实测结论 (E5 结构、E6 剂量、E7 状态条件、E11 稳健、E3 普遍、 $g=1.3$ -vs- 1.0 FID) 共同钉死诊断定位: 非标量残差存在、有结构、状态条件、普遍、无害——带它的臂质量更好。

5.3 E1 — 跨状态残差轨迹

假设 5.1 (残差预测失败)。跨训练状态, 非标量残差的大小 (以 $R_{\text{opt}} - R_{\text{grad}}$, 或 h_{update} 的坐标离散度量) 预测 FID 退化与不稳定: 残差越大, FID 越差和/或梯度范数、loss 方差越高。

方法。在同一运行的若干 checkpoint(32/64/128/256 kimg) 上执行现有 stateful audit, 记录各状态的 R_{opt} 、 R_{grad} 、 h_{update} 与 off-support energy; 并采集各状态的 FID 与稳定性代理 (梯度/loss 方差)。计算残差大小与 FID、不稳定性的 Spearman 相关。

判定。若相关显著为负、且跨 ≥ 4 个状态对支撑阈值稳健, 则通过; 若残差平坦或无关, 则判定其为现象而非原因, 实验不通过。

风险。中间状态 FID 方差较大, 可采用 KID-5k 作为低方差代理并跨 seed 平均。状态数量有限时检验力不足, 可补充使用 paired sweep 的每步残差序列。

5.4 E2 — 因果干预 (residual-corrected update)

假设 5.2 (残差可修复且具有危害). 移除 *gap* 效应的非标量部分——将候选梯度投影至参考方向后再执行 *optimizer step*——相对未修正臂可改善训练稳定性与 *FID*。

方法 (paired 三臂设计, 本项目一贯方法)。自同一状态:

- Arm R(参考): $g = 1.0$, 标准 RAdam, 提供 G_1 与 U_1 。
- Arm U(未修正): $g = 1.3$, 标准 RAdam, 非标量残差存在。
- Arm C(修正): $g = 1.3$, 梯度修正为 $G_{\text{corr}} = s^* G_1$, $s^* = \langle G_g, G_1 \rangle / \|G_1\|^2$, 移除非标量内容, 使 $h \rightarrow 1$ 。

在短窗口 (16–64 kimg) 内比较 Arm U 与 Arm C 的稳定性与 *FID*。

设计依据。gap 干预含标量部分 (可被学习率吸收) 与非标量部分 (残差)。Arm C 仅改动非标量部分。若 Arm C 稳定性或 *FID* 优于 Arm U, 则残差为退化的原因, 修复即为治疗。

判定。若 Arm C 显著更稳定或 *FID* 更好、跨 seed 稳健, 则通过; 若 $\text{Arm C} \approx \text{Arm U}$, 则判定残差无害且不可修复, 实验不通过。

风险。Arm C 每步需参考梯度, 须与 Arm R 并行, 计算量约 2–3 $\times$; 可采用短窗口或仅在部分步计算 G_1 。修正可能过强, 削除合法非标量信号——若 Arm C 反而更差, 应如实记录, 该结果本身亦具信息量。

5.5 E3 — 普适性

假设 5.3 (残差为普遍现象)。非标量残差是一般的 *optimizer-state* 现象, 而非 *CIFAR-10/ECM/RAdam* 或 (1.0, 1.3) *gap* 对的特定产物。

方法。采用第二 optimizer (AdamW 或 Muon 系)、第二数据集/backbone (ImageNet-64 或小型 DiT)、第二 gap 对, 重复审计; 报告 {optimizer $\times$ dataset $\times$ gap} 网格上的残差大小。

判定。若残差跨 ≥ 2 个 optimizer 与 ≥ 2 个数据集/backbone 复现, 则通过; 否则普适性声明需收缩, 并作为 limitation 报告。

风险。ImageNet-64/DiT 全量训练成本高; 可改用单步 paired audit。Muon 系 optimizer 或未安装, AdamW 足以支撑”第二 optimizer”的声明。

5.6 E4 — MeanFlow / flow-map 泛化

假设 5.4 (前沿相关性)。非标量残差机制在 *MeanFlow / flow-map* 训练中复现, 并关联至 *MeanFlow* 不稳定 / 无界梯度方差的开放问题。

方法。将 paired counterfactual 机制适配至 flow-map / MeanFlow 目标; 在 MeanFlow 训练状态上执行 stateful audit; 可行时施加 E2 修正并检验训练是否稳定。

判定。若残差在 MeanFlow 上复现, 且理想情况下修正可稳定训练, 则通过。须专门关联命名的那个不稳定问题, 而非笼统声称在 MeanFlow 上运行过。

风险。成本高且可能不复现, 故门控于 E1+E2 之后。

5.7 E5 — 残差结构分解

假设 5.5 (残差具有结构). 非标量残差 E_j 并非随机噪声, 而是具有结构: 与坐标梯度幅值、层深度或局部曲率相关, 且可能存在主导方向。

方法. 对残差 E_j 做多维度分解: (i) 按层聚合, 检验残差是否随层深单调变化; (ii) 按坐标梯度幅值 $|G_{j,i}|$ 分箱, 检验残差是否与幅值相关; (iii) 计算残差与梯度方向、与局部 Hessian 对角近似的相关; (iv) 检验残差是否近似为梯度的确定性函数 (如 $E_j \approx c G_j + \varepsilon$), 并估计其主导方向。

判定. 若残差在层、幅值或方向上呈现可复现的相关性, 则其为真实机制而非噪声; 该结构同时为 E8 的诊断提供特征。

风险. 残差可能接近各向同性噪声, 无明显结构——若如此, 应如实报告, 这并不否定残差的存在, 但会削弱可预测性主张。

5.8 E6 — 剂量响应 (残差对 gap 的响应)

假设 5.6 (残差为干预的系统函数). 非标量残差的大小随 gap 大小系统性变化, 呈现单调或近线性关系。

方法. 在多个 gap 值 (如 0.8, 1.0, 1.1, 1.3, 1.5) 上重复 stateful audit, 绘制残差大小 (及 h_{actual} 偏移) 对 gap 的响应曲线, 并拟合其标度关系。

判定. 若残差随 gap 单调或近似线性变化, 则该现象为干预的定量规律, 而非偶然; 该关系为论文提供一条可量化的定律。

风险. 小 gap 下残差可能淹没在数值噪声中; 需确保支撑阈值与数值精度足以分辨。

5.9 E7 — 优化器状态依赖

假设 5.7 (残差效应依赖优化器状态). 对固定的梯度残差, 其导致的更新失真 (h 对 1 的偏移) 随优化器状态 (一阶矩 m 、二阶矩 v 的幅度) 而变化。

方法. 在固定 gap 下, 取同一网络的不同优化器状态 (暖启动早期的小矩 vs. 成熟期的大矩), 测量相同梯度残差所对应的 h_{actual} 偏差。比较偏差是否随状态变化。

判定. 若同一梯度残差在不同状态下产生不同更新失真, 则“state-conditioned”这一核心主张成立——即优化器状态本身在起作用, 而非仅梯度。这是将理论 gauge 故事接到数据的关键一环。

风险. 若失真对状态不敏感, 则“状态条件”主张需弱化; 此时更新失真主要由梯度残差本身决定。

5.10 E8 — 坐标级诊断的有效性

假设 5.8 (残差可预测). 存在一个坐标级预测器 (基于 $gauge$ 、 $|m|$ 、 $|v|$ 、 $|G|$ 等特征) 能在未见状态上预测哪些坐标违反标量等价 (即 $h_{k,i}$ 远离 1)。

方法. 从 $gauge/moment$ 特征构建一个残差预测器, 在某一状态上拟合, 在另一状态上测试。以“坐标为 h 远离 1”为二分类目标, 报告 AUC 与校准度。

判定。若预测器跨状态泛化 (测试 AUC 显著高于随机), 则残差可预测——这是”可预测且可修正”中的”可预测”半边, 使 E2 的修正是基于诊断而非预言机。

风险。若预测器不跨状态泛化, 则残差虽存在但不可预测, 需弱化”可预测”主张, 并退化为仅依赖 E2 的干预性证据。

5.11 E9 — 修正的权衡

假设 5.9 (修正存在帕累托前沿). 以强度参数 α 在未修正梯度 G_g 与完全投影 s^*G_1 之间插值 ($G_{\text{corr}} = (1 - \alpha)G_g + \alpha s^*G_1$), 稳定性与 FID 随 α 呈现权衡, 存在最优区间。

方法。扫描 $\alpha \in [0, 1]$, 对各取值训练短窗口并测量稳定性与 FID, 绘制 $(\alpha, \text{稳定性}, \text{FID})$ 曲面。

判定。若存在 α 的帕累托前沿或最优区间, 则修正成为带旋钮的真实方法而非二元开关, 增强其实用性。

风险。若修正不带来任何改善或不存在权衡区间, 则 E2 的”修正有益”主张需收缩; 应如实报告。

5.12 E10 — 修复的基线对照

假设 5.10 (修正具有针对性). *residual-corrected update* 相对简单基线 (降学习率、梯度裁剪、逐坐标梯度裁剪、AdamW) 具有针对性优势——其收益来自专门移除非标量残差, 而非通用的稳定化。

方法。将 Arm C 与下列基线在相同设置下比较: 降低学习率、全局梯度裁剪、逐坐标梯度裁剪、切换 AdamW。以稳定性与 FID 为指标。

判定。若 Arm C 相对基线持平或占优, 则修正的针对性得到支持; 这预先回应”直接降学习率即可”的反驳。

风险。若简单基线已达同等效果, 则修正的必要性主张需弱化, 但仍可保留机制层面的价值。

5.13 E11 — 稳健性: 多 seed 与支撑阈值敏感性

假设 5.11 (结论对超参稳健). E1、E2 的主要结论对随机种子与有效支撑阈值 (*support_atol*) 稳健。

方法。以多个随机种子重复 E1、E2; 在若干支撑阈值下重算全部 gauge 统计量, 检验结论是否随阈值漂移。

判定。若主要结论 (残差预测失败、修正有益) 在种子与阈值下稳定, 则 soundness 得到保障——这是 ICLR 最看重的标准。

风险。若结论对支撑阈值敏感, 则需报告敏感性区间并明确其适用边界。

5.14 E12 — 残差中介 gap 到 FID

假设 5.12 (残差中介质量效应). 非标量残差 (部分) 中介了 gap 干预对 FID/质量的影响: 在控制残差后, gap 对 FID 的效应显著削弱。

方法。结合 E6 的剂量响应状态, 做中介式分析: 检验残差在 gap 对 FID 的回归中解释的方差, 是否超出标量部分所能解释的方差; 若控制残差后 gap 的效应下降, 则残差为质量退化的部分原因。

判定。若残差解释了 gap 到 FID 方差的显著部分, 则”so what”得以直接确立——把整个优化器分析连接到生成质量, 而非停留在更新几何层面。

风险。中介分析依赖因果假设与充足的状态数; 若 FID 噪声大或状态不足, 中介效应难以识别, 应如实报告并为结论加限。

6 执行顺序与约束

6.1 执行顺序

实验分三阶段推进, 前两阶段决定论文类型, 第三阶段为完整化:

阶段一 (门控, 决定机制):

顺序	实验	决定内容	工作量
1	E1 跨状态残差	残差预测失败 (机制)	低 (复用 audit)
2	E5 残差结构分解	残差有结构而非噪声	低
3	E6 剂量响应	残差为干预的系统函数	低
4	E7 优化器状态依赖	state-conditioned 成立	中
5	E2 因果干预	修正有益 (方法)	中 (新代码)

阶段二 (验证修复, 决定方法强度):

顺序	实验	决定内容	工作量
6	E8 诊断有效性	残差可预测	中
7	E9 修正权衡	修正为可调方法	中
8	E10 修复基线	修正具有针对性	中

阶段三 (完整化, 建立意义与稳健):

顺序	实验	决定内容	工作量
9	E12 残差中介 gap 到 FID	直接”so what”	中
10	E11 稳健性	soundness 保障	低
11	E3 普适性	强化	中
12	E4 MeanFlow	前沿	高

关键检查点: 阶段一 E1 与 E2 均通过 → 论文为机制加方法, 推进阶段二、三。E2 未通过 → 撰写诊断论文, 转投兜底 workshop, 不进入阶段三的 E12/E4。

6.2 各实验不得声称什么

- E1 须展示预测而非仅存在——即跨状态的相关, 而非单点观测。

- E2 须展示修正改善下游指标, 而非仅将 h 恢复至 1 (恢复 h 是必要条件, 而非充分条件)。
- E5–E7 须展示残差具有可复现结构, 而非单次测量的巧合。
- E8 须展示预测器跨状态泛化, 而非仅在拟合状态上有效。
- E9 须展示修正的权衡, 而非无条件的改善。
- E10 须展示修正相对基线的针对性, 而非通用稳定化。
- E12 须展示残差中介质量效应, 而非仅与质量相关。
- E3 须展示残差普遍存在, 而非仅在一个配置中出现。
- E4 须关联命名的 MeanFlow 不稳定问题, 而非笼统地运行于 MeanFlow。
- 任何实验均不得声称 “first”(见第 4 节)。

7 结论

诚实的负结果——标量等价在少步训练中失效, 且主导失真是非标量梯度内容——在 2025–26 文献中此前未被直接研究。当前项目将该发现置于文末作为结论性说明, 属结构失当。对抗性审查 (见 ‘docs/ICLR2027_PLAN_REVIEW.md’) 表明, “机制 + 方法 40–50%” 的估计过度乐观; 而 **干净的 $g=1.3$ vs. $g=1.0$ FID 实测** (见 ‘analysis/g13_vs_g10_fid_result.md’) 已把前提判定钉死: 带非标量残差的 $g=1.3$ 臂在 FID/KID 上全面大幅胜出 ($-34\%/-45\%$), 残差无害, E2 因果干预被反指。三重实测证据 (Arm C scale-matched control、P1 附庸性检验、未来预测梯度级阴性) 一致指向: 非标量梯度残差是真实但 (梯度级) 无后果的现象——质量改善大部分是平凡 LR 重缩放 (Arm C 消除 84–100%)、残差附庸于标量 gap (偏相关 ≈ 0)、早期梯度残差不预测未来 FID。优化器记忆机制仍真实 ($h_{\text{actual}} \neq h_{\text{pred}}$), 但其质量后果大部分平凡。唯一剩余活口是优化器级未来预测 (早期 R_{opt} , 需重训存早期 optimizer state), 但鉴于 Arm C 翻盘概率不高。论文定位为诚实的诊断论文 (非标量梯度内容的存在、结构与质量方向, 约 20–30%), 可辩护但非 “化腐朽为神奇”。E2 降级为探索性消融与设计启示。Go/No-Go 交 leader 判断: 是否花计算测优化器级未来预测, 还是接受三重证据定 workshop。目标自始至终唯一: 使论文进入 ICLR 2027——但须基于对前提的实测检验, 而非乐观假设。

参考文献

- [1] D. Kingma and J. Ba, “Adam: A method for stochastic optimization,” *ICLR*, 2015.
- [2] L. Liu et al., “On the variance of the adaptive learning rate and beyond,” *ICLR*, 2020.
- [3] G. et al., “Adam on local time: addressing nonstationarity in RL with relative Adam timesteps,” *NeurIPS*, 2024.
- [4] “LoRA Done RITE,” *ICLR*, 2025.

- [5] “Why Adam works better with $\beta_1 = \beta_2$: the missing gradient scale invariance principle,” arXiv:2601.21739, 2026.
- [6] “Adaptive discretization for consistency models,” *NeurIPS*, 2025.
- [7] “Stable consistency tuning,” arXiv:2410.18958, 2024.
- [8] “Dead-direction conditioners: gauge-equivariant preconditioning for deep networks,” arXiv:2606.29176, 2026.